

초급 데이터 분석 · 1교시

1교시 — 데이터 분석, 왜 그리고 어디로

이 강의는 이렇게 진행합니다

- 전 과정 5교시 — 이론(PPT) 중심으로 큰 그림과 사고방식을 잡는다
- 실습 노트북은 '셀프스터디'용 — 나중에도 다시 돌려볼 수 있다
- 오늘 1교시는 '개론 + 기초 이론' — 통계·데이터 보는 법까지 다룬다

1교시

개론+기초이론
(오늘)

2교시

데이터 들여다보기

3교시

정제·나눠보기

4교시

시각화

5교시

프로젝트+로드맵

오늘의 여정

1교시, 이렇게 흘러갑니다



오늘 목표: 데이터 분석의 큰 그림 + '기초 이론'(통계·데이터 보는 법)을 손에 쥐기

게임의 규칙:

**데이터를 보여드릴 테니,
여러분의 '당연한 결론'이 맞는지 봅시다.**

1

왜 데이터 분석인가

감(感)으로는 부족하다

왜 · 의사결정

우리는 매일 '결정'을 한다

- 개인: 점심 뭐 먹지? 이 수업 들을까? 어느 회사에 지원하지?
- 기업: 이 제품 낼까? 가격 올릴까? 누구를 뽑을까?
- 좋은 결정 = 좋은 근거에서 나온다 → 그 '근거'를 만드는 일이 분석

왜 · 두 방식

결정의 두 가지 방식

① 감(感)으로

"왠지 잘 될 것 같아"

경험·직관·느낌

② 데이터로

"지난 3개월 숫자를 보니"

근거·증거

둘 다 필요하다. 하지만 '감'에만 기대면 — 위험하다.

왜 · 감의 한계

감(직관)은 이렇게 틀린다

- 편향된다 — 보고 싶은 것만 보고, 믿고 싶은 걸 믿는다
- 기억에 속는다 — 강렬한 한 사건을 '전체'로 착각
- 큰 수·복잡함에 약하다 — 수천 줄 데이터를 머리로 못 본다


왜 · 사례

감만 믿다 무너진 거인들

- 코닥: 디지털카메라를 먼저 만들고도 '필름이 돈'이라는 감으로 외면 → 몰락
- 블록버스터: '사람들은 빌리러 나온다'는 감 → 넷플릭스에 밀려 파산
- 감은 '과거의 성공'에 갇힌다 — 데이터는 '지금의 변화'를 보여준다

왜 · 전환

그래서 — '감'에서 '데이터 기반'으로



"데이터로 결정하는 조직이, 감으로 결정하는 조직을 이긴다"
넷플릭스 추천·아마존·스포츠 머니볼이 증명했다.

왜 · 정의

데이터 분석이란

데이터에서 패턴을 찾아,
'결정에 쓸 답'을 만드는 일.

2

데이터란 무엇인가

보는 눈의 기초

무엇 · 구조

'정형 데이터'는 이렇게 생겼다 (표)

한 줄 = 한 명(관측치)

이름	학과	점수
김철수	경영	85
이영희	컴공	92
박민수	디자인	78

↑ 한 세로줄 = 하나의 '변수'(이름·학과·점수)

데이터는 숫자만이 아니다

정형 데이터

표로 깔끔히 정리되는 것
매출표·성적표·센서값
→ 이 강의가 주로 다루는 것

비정형 데이터

표로 안 떨어지는 것
사진·영상·글(리뷰)·음성
→ 요즘 AI가 잘 다루는 것

변수에도 '종류'가 있다

범주형 (질적)

종류·이름을 나타냄

명목형: 성별, 혈액형, 학과

순서형: 학점($A > B > C$), 만족도

수치형 (양적)

숫자로 크기를 나타냄

이산형: 자녀 수, 방문 횟수

연속형: 키, 몸무게, 매출

무엇 · 변수

변수 종류가 '분석 방법'을 결정한다

- 범주형 → 개수를 센다(빈도), 막대그래프로 비교
- 수치형 → 평균·표준편차를 구한다, 히스토그램·산점도
- 예) '성별(범주)별 평균 키(수치)' = 범주로 나눠 수치를 비교 → 가장 흔한 분석

변수의 종류를 먼저 보면, 무엇을 어떻게 분석할지가 보인다

무엇 · 현실

현실의 데이터는 '지저분'하다

- 빈 칸(결측치): 나이를 안 적은 사람
- 이상한 값(이상치): 키 250cm, 나이 -3
- 형식 불일치: '서울' vs '서울특별시', "19,500"(쉼표 든 숫자)

"쓰레기가 들어가면 쓰레기가 나온다" — 정제가 분석의 절반 (3교시에서 실습)

3

함정① 평균의 함정

→ 그래서 '기본 통계'를 배운다

남시 ① · 상황

채용 공고에서 이런 문구를 봤다

"우리 회사,
평균 연봉 5,000만원!"
— 신입 환영 🎉



당신의 판단은?

이 회사, 지원할 만한가요?

"평균 5천이면 괜찮지" 싶죠?

남시 ① · 예상

대부분 "괜찮은데?" 합니다

"평균이 5천이면, 나도 그쯤 받겠지"

— 자연스러운 기대입니다.

그런데... 그 회사 안을 들여다보면?

남시 ① · 반전

실제로 열어보니... 이렇다

"우리 회사 평균 연봉 5천만원!" ... 진짜?



사장님 혼자 5억. 직원 9명은 3천만원대. 그래도 '평균'은 5천만원.

평균은 5천만원,
직원 9명은 3천만원대?

평균, 믿어도 될까요?

그래서, 데이터를 '요약'하는 법:

기본 통계

수천 개의 숫자를, 몇 개로 줄여 본다

데이터의 '가운데'를 재는 3가지

평균

모두 더해 개수로 나눔

극단값에 약함

중앙값

줄 세웠을 때 딱 가운데

극단값에 강함

최빈값

가장 자주 나오는 값

범주형에 유용

공식: 평균 = 모든 값의 합 ÷ 개수

평균이 좋을 때 vs 중앙값이 좋을 때

평균을 쓰자


값이 고르게 퍼져 있을 때
예: 우리 반 키, 시험 점수

중앙값을 쓰자

극단값이 섞여 있을 때
예: 연봉, 집값, 재산

뉴스의 '평균'을 볼 때마다 의심하라: 혹시 극단값에 휘둘렸나?

'분포'를 보면 평균의 함정이 보인다




왼쪽(대칭)은 평균=중앙값. 오른쪽(치우침)은 평균이 끌려간다 — 연봉이 이 경우.

'가운데'만으로는 부족하다 — 퍼짐

- 같은 평균이라도 '얼마나 흩어졌나'가 다르다
- 범위 = 최댓값 - 최솟값 (가장 단순)
- 분산 = $(\text{각 값} - \text{평균})^2$ 의 평균 / 표준편차 = $\sqrt{\text{분산}}$

표준편차 = "평균에서 평균적으로 얼마나 떨어져 있나" (클수록 들쭉날쭉)

평균이 같아도 '표준편차'가 다르다



같은 평균 50점이라도, 파란 반은 안정적·주황 반은 들쭉날쭉. 평균만 보면 못 본다.

데이터를 요약할 땐, 셋을 함께

중심

평균·중앙값·최빈값
어디에 모였나

퍼짐

범위·표준편차
얼마나 흩어졌나

분포

히스토그램
어떤 모양인가

숫자 하나(평균)가 아니라 — 중심 + 퍼짐 + 분포를 함께 봐야 진짜가 보인다

낙시 ① 교훈

"평균"이라는 한 숫자에 속았다.

→ 중심·퍼짐·분포를 함께 보라.

4

함정② 생존자 편향

→ 그래서 '데이터를 의심하는 법'


2차 세계대전, 실제 있었던 이야기

- 전투기를 적 총격에서 지키려 한다 → 어디에 장갑을 덧댈까?
- 돌아온 비행기들의 총알 자국을 전부 표시했다
- 자국은 주로 '날개·꼬리·동체'에 몰려 있었다

낚시 ② · 데이터

돌아온 전투기의 총알 자국

돌아온 전투기의 총알 자국



빨간 점 = 총알 자국. 날개·꼬리·동체에 잔뜩, 엔진·조종석엔 거의 없다.



당신이 사령관이라면?

어디에 장갑을 덧대시겠습니까?

총알 많이 맞은 곳? 적게 맞은 곳?

거의 모두 "자국 많은 곳"이라 답한다


"총 많이 맞은 날개·꼬리를 보강하자"
— 너무나 당연해 보입니다.

그런데 한 통계학자가 정반대를 외쳤습니다.

남시 ② · 반전

"엔진과 조종석을 보강하라"

진짜 보강할 곳 = 자국이 '없는' 곳



보강할 곳은 자국이 '없는' 곳. 왜?!

남시 ② · 해부

우리가 본 건 '돌아온' 비행기뿐이다

- 조사한 비행기 = 살아 돌아온 비행기 (생존자)
- 엔진·조종석에 자국이 없는 이유 → 거기 맞은 기체는 '돌아오지 못해서'
- 안 보이는 데이터(추락한 기체)가 진짜 답을 주고 있었다

이것이 '생존자 편향' — 살아남은 것만 보면 정반대 결론에 이른다

"이건 누구의 데이터인가?"

- 모든 데이터는 '일부'다 (표본) — 전체(모집단)를 대표하나?
- 표본이 한쪽으로 치우치면(편향) → 결론도 치우친다
- 예: '앱 사용자 설문'은 앱 안 쓰는 사람을 못 본다

이 함정, 여러분 일상에도 있다


- "성공한 창업자" 인터뷰만 보고 따라하기 — 실패한 다수는 말이 없다
- "합격 수기"만 읽기 — 같은 방법으로 떨어진 사람은 글을 안 쓴다
- "이 코인으로 벌었다" 후기 — 잃은 사람은 조용하다

성공 사례만 보면, '보이지 않는 실패'가 진실을 가린다

보는 법 · 상관 ≠ 인과

둘이 같이 움직인다 — 원인일까?

둘은 같이 늘어난다 (양의 상관) — 그럼 아이스크림이 원인?



아이스크림이 늘면 익사도 는다. 그럼 아이스크림이 익사의 원인?

보는 법 · 상관≠인과

'같이 움직인다' ≠ '원인이다'



둘 다 '여름' 때문에 늘었을 뿐, 서로 원인이 아니다.
상관관계를 인과관계로 착각하면 — 엉뚱한 결정을 내린다.

데이터를 볼 때 던질 질문

- 이건 '누구의' 데이터인가? (표본·편향)
- '안 보이는' 데이터는 없나? (생존자 편향·결측)
- 같이 움직인다고 '원인'이라 단정하지 않았나? (상관 ≠ 인과)

낙시 ② 교훈

'보이는 것'만 믿으면 속는다.

→ 표본·안 보이는 것·인과를 의심하라.

5

함정③ 심슨의 역설

→ 그래서 '전체 보기'에서 '나눠 보기'로


남시 ③ · 상황

1973년, UC버클리에서 실제로 벌어진 일

- 명문 UC버클리 대학원 입시 결과가 발표됐다
- 남성 합격률이 여성보다 눈에 띄게 높았다
- "여성 차별 아니냐" 논란 → 대학이 소송까지 당했다

남시 ③ · 데이터

전체 합격률 — 남성이 더 높다



남성 44% vs 여성 35%. 9%p 차이.



어떻게 보이나요?

이 숫자, '여성 차별'의 증거일까요?

숫자만 보면 그래 보입니다.

남시 ③ · 예상


숫자만 보면 "차별"로 읽힌다

"전체에서 남성이 9%p나 높으니 차별?"
— 합리적인 의심입니다.

그런데 — '학과별로' 나눠 봤더니?

남시 ③ · 반전

학과별로 나누니 — 뒤집혔다!



대부분 학과에서 오히려 '여성' 합격률이 같거나 높다 (6개 중 5개).

전체로는 남성이 높는데,
학과별론 여성이 높다?

대체 무슨 일이?

남시 ③ · 해부

범인은 '어느 학과에 지원했나'였다

- 여성은 경쟁이 치열한(합격률 낮은) 학과에 더 많이 지원했다
- 남성은 합격이 쉬운 학과에 더 많이 지원했다
- 각 학과는 공정했지만 '지원 분포' 차이가 전체 평균을 뒤집었다

이것이 '심슨의 역설' — 합쳐 보면 반대로 보이는, 숨은 변수의 장난

그래서, 데이터를 보는 순서:

전체 보기 → 나눠 보기

큰 그림을 잡고, 반드시 쪼개서 확인한다

전체 보기 — 큰 그림부터

- 요약통계로 데이터 전체를 한눈에: 개수·평균·최솟값·최댓값·분포
- "이 데이터, 대충 어떻게 생겼나"를 먼저 파악
- 2교시에서 describe() 한 줄로 이걸 다 본다 (예고)

나눠 보기 — 쪼개야 진실이 보인다

- 기준(그룹)으로 쪼개 비교한다: 성별·지역·등급·기간별
- 전체 평균이 숨긴 차이가 그룹별로 드러난다 (심슨의 교훈!)
- 3교시에서 groupby로 직접: '객실 등급별 생존율' 같은 분석

"전체 평균"을 본 뒤엔, 반드시 "나눠서" 다시 본다

보는 법 · 시각화

나눠 본 걸 '그림'으로 — 차트 4종

막대
그룹 비교

히스토그램
분포 보기

산점도
관계 보기

박스
그룹별 분포

무엇이 궁금한가에 따라 차트를 고른다 (4교시에서 직접 그린다)

낙시 ③ 교훈

합친 평균만 보면 속는다.

→ 전체를 본 뒤, 반드시 나눠서 보라.

데이터는 한 가지로만 속이지 않는다

① 평균의 함정

"평균"에 속는다
→ 분포를 보라

② 생존자 편향

"안 보이는 것"에 속는다
→ 없는 데이터를 보라

③ 심슨의 역설

"안 나누면" 속는다
→ 나눠서 보라


감도 틀리고, 데이터도 잘못 읽으면 속는다 — 그래서 '제대로 보는 법'을 배운다

6

기업은 데이터를 어떻게 쓰나

수집 → 처리 → 분석 → 활용

데이터는 이 네 단계를 거친다



모으고 → 깨끗이 다듬고 → 패턴을 찾고 → 결정·행동으로 옮긴다
오늘 배운 통계·나눠보기는 바로 ③ 분석 단계의 도구다

데이터는 어디서 오나

- 사용자 로그: 클릭·구매·시청 기록 (앱·웹)
- 센서·기기: 위치·온도·심박수 (IoT·웨어러블)
- 설문·기록: 만족도 조사, 거래 장부
- 공공데이터: 국토부 실거래가, 기상청 등 (무료 공개)

① 구조에 따라 — 정형·반정형·비정형

정형

행·열의 표로 딱 떨어짐

매출표·회원DB·센서값

저장: 관계형 DB(RDB)

SQL로 조회

반정형

구조는 있지만 표는 아님

JSON·XML·웹/앱 로그

저장: NoSQL·문서DB

(MongoDB 등)

비정형

형식이 없는 '날것'

이미지·영상·음성·자유 텍스트

저장: 객체 스토리지

·데이터 레이크

세상 데이터의 약 80%가 '비정형' — 다루기 어렵고, 그래서 요즘 AI가 중요해졌다

② 들어오는 속도에 따라 — 배치·실시간·이벤트

배치(Batch)

모았다가 주기적으로 한 번에
야간 매출 정산·월말 집계
단순·저렴, 느려도 OK

실시간/스트리밍

흘러드는 즉시 처리
주가 시세·센서·실시간 로그
빠름·복잡 (Kafka 등)

이벤트 드리븐

특정 '사건'이 생길 때 작동
클릭→기록, 결제→알림 발송
느슨하게 연결

"얼마나 빨리 필요한가(지연시간)"가 처리 구조를 가른다

③ 어디에 담나 — OLTP vs 데이터 웨어하우스

OLTP — 거래 처리용

- 목적: 지금 일어나는 거래 기록·조회
- 작은 읽기/쓰기가 매우 빈번
- 행(row) 지향 저장 · 정규화
- 예: MySQL, PostgreSQL, Oracle

비유: 가게 '금전등록기'


DW(OLAP) — 분석용 창고

- 목적: 대량 데이터 집계·분석
- 큰 범위를 한 번에 읽어 요약
- 열(column) 지향 → 집계 빠름
- 예: BigQuery, Snowflake, Redshift

비유: 분석용 '대형 창고'

왜 나눌까? 거래용 DB에서 무거운 분석을 돌리면 서비스가 느려진다 → 분석 데이터는 DW로 따로

④ 옮기고 다듬기 — ETL / ELT



ETL = 추출→변환→적재(전통) / ELT = 먼저 적재 후 변환(클라우드 DW 시대)

파이프라인 도구: Airflow(스케줄)·dbt(변환) 등

여기서 'Transform(변환·정제)' = 3교시에서 직접 배울 데이터 정제와 같은 일!

가장 오래 걸리는, 가장 안 보이는 단계

- 현실 데이터는 지저분 → 결측·이상치·형식 통일 (정제)
- 분석가가 시간의 절반 이상을 여기에 쓴다
- 화려하지 않지만, 여기서 품질이 갈린다 (3교시 실습)

"쓰레기가 들어가면 쓰레기가 나온다" — 처리(정제)가 분석의 절반

⑤ 너무 크면? — 병렬·분산 처리

- 데이터가 한 대의 컴퓨터로 감당 안 되면 → 여러 대가 '나눠서 동시에' 처리
- 맵리듀스(MapReduce): 잘게 나눠(Map) → 각자 처리 → 합치기(Reduce)
- 대표 도구: 하둡(HDFS, 분산 저장) · 스파크(Spark, 빠른 분산 연산)

비유: 1,000만 행을 한 명이 처리 vs 100대가 10만 행씩 나눠 처리 → 훨씬 빠르게

'빅데이터'가 가능해진 핵심 기술 — 일을 쪼개 여러 컴퓨터가 함께 한다

⑥ 큰 그림 — 웨어하우스 vs 레이크

데이터 웨어하우스

정제된 '정형' 데이터 창고

분석 최적 · 구조 명확

비싸고 덜 유연

데이터 레이크

원본 그대로 모은 '호수'

정형+비정형 다 담음

싸고 유연 · 정리 필요

레이크하우스

둘의 장점을 결합

요즘 뜨는 통합 방식

Databricks 등

한 줄 정리: "정제본은 창고(DW)에, 원본은 호수(Lake)에" — 둘을 합친 게 레이크하우스

활용 · ③④ 분석·활용

찾은 패턴을 '결정'으로 바꾼다

③ 분석

전체 보기 → 나눠 보기
통계·시각화로 패턴 찾기

④ 활용

"그래서 무엇을 할까"
가격·타겟·전략 결정

분석은 '숫자 내기'가 아니라 '결정으로 잇기'에서 완성된다

활용 · 분야

거의 모든 분야가 데이터로 움직인다

마케팅

고객·추천

금융

투자·이상거래

의료

진단·예측

공공

교통·재난

스포츠

선수·전략

분야는 달라도 본질은 같다: 데이터로 더 나은 결정을 내린다

마케팅

- 고객 세분화(단골/이탈위험)
- 추천: '함께 산 상품'
- A/B 테스트로 결정

의료

- 검진 수치로 위험 예측
- X-ray·CT 판독 보조(AI)
- 최종 진단은 의사 몫

공공 · 스포츠 · 금융

공공

교통량 예측·재난 조기대응

스포츠

'머니볼' — 데이터로 선수 선발

금융

투자·이상거래 탐지·신용평가

머니볼: 약팀이 데이터로 강팀을 이긴 실화 — '감'을 데이터가 이겼다

비트코인 — 저도 이 데이터를 봤습니다

비트코인 — 데이터는 무엇을 말하고 있었나?



"다들 더 오른다"던 그때, 데이터는 무슨 말을 하고 있었을까요?

활용 · 강사 현장

부동산 실거래가 — 진짜 공공데이터

- 국토교통부 공개 '실제 아파트 거래 기록' (로그인 없이 누구나)
- 감이 아니라 데이터로 '어느 동네가 오르나' 확인
- 3교시에 직접 만진다 — "19,500" 같은 지저분한 값 정제

분야가 마케팅이든 금융이든 의료든,

하는 일은 똑같습니다:

질문 → 데이터 → 해석.


7

AI 시대의 데이터 분석

도구가 바뀐다 — 그리고 너희 진로도



에이전트가 '분석 파이프라인'을 돈다



 예전엔 사람이 며칠 걸리던 이 과정을, 에이전트가 분 단위로 시도한다

자연어로 "분석해줘" → 자동 리포트·이상탐지까지



솔직한 질문

그럼... 입문 분석가는 필요 없어지나?

사라지는 일 vs 남는 일

사라진다 (AI가 흡수)

- 단순 SQL 추출·CSV 청소
- 기본 대시보드·반복 검증
- 수작업 문서화

남는다·커진다 (사람 몫)

- 결과를 '검증'하기
- 의미를 '해석'하기
- 비즈니스 '판단'

역할이 '이동'한다 (없어지는 게 아니라)

- AI는 '대체'가 아니라 '증강' — 기업 78%가 그렇게 쓴다 (McKinsey)
- 채용 약 85%가 '경력 무관' — 연차보다 실력을 본다 → 입문자에게 기회
- 단, '실력'의 정의가 바뀌었다: 도구질 → 검증·해석·판단

기업이 말하는, 신입에게 가장 부족한 능력 = "AI 결과를 검증하는 힘"

AI · 인정

요즘 AI, 계산은 정말 잘한다

- 사칙연산·코드 실행·표 요약·차트 — 이제 거의 다 잘한다 (여러분이 매일 쓰니 안다)
- "이 데이터 분석해줘" 하면 깔끔한 숫자와 그래프를 척척 내놓는다
- 그러니 진짜 문제는 "AI가 계산을 틀리나"가 아니다 — 다른 데 있다

AI는 '당신이 물은 것'에 '당신이 준 데이터'로 — 충실하게 답할 뿐이다

AI는 당신의 '함정'을 그대로 물려받는다

 (연봉 데이터를 주며) "우리 회사 평균 연봉 알려줘" →  "5,000만원입니다"
 계산은 정확하다. 그런데 — 오늘 배운 그 '평균의 함정'을 AI는 먼저 안 짚어준다.

- 평균만 물으면 평균만 준다 — "중앙값도 보세요"라고 먼저 말 안 한다
- 전체 합격률만 물으면 전체만 준다 — "학과로 나눠보라"(심슨)고 먼저 말 안 한다
- = 평균·생존자·심슨, 오늘의 함정에 AI도 똑같이 빠진다 (당신이 안 짚으면)

AI는 답을 '계산'해줄 뿐 — 무엇을 물을지, 그 답이 말이 되는지는 묻지 않는다

오늘 단 하나만 가져간다면 —
AI는 '계산'을 대신해줘도,
무엇을 묻고 어떻게 의심할지는 — 당신의 몫이다.

8

그래서, 우리가 할 일

도구는 변해도, 남는 것

정리 · 사람의 몫

속지 않는 사람의 두 가지 힘

1

좋은 질문을 던지는 힘

"무엇을, 어떻게 나눠 물을까"
질문이 영성하면 답도 영성

2

검증·해석하는 힘

"이게 말이 되나? 따져보자"
오늘 네 번의 속임수를 쫓 힘

오늘, 약속대로 네 번 속았습니다

① 평균

평균 연봉의 함정

② 생존자

돌아온 비행기만 봤다

③ 심슨

안 나뉘서 뒤집혔다


④ AI

물은 것만 답해서

분석을 배운다 = "안 속는 기술 + 좋은 질문"을 익히는 것

도구는 변해도,
좋은 질문을 던지고 결과를 해석하는 힘은
사람의 몫이다.

그래서 — 다음 4교시, 직접 해본다



오늘 배운 통계·전체/나뉘보기를, 다음 교시에 코드로 직접 해본다

이론은 PPT, 실습은 셀프스터디 — 정답 보며 집에서

다음 교시 —

직접 데이터를 만지기 시작합니다. 🚀