

초급 데이터 분석 · 2교시


데이터와 친해지기 — 탐색의 기술

— 분석하기 전에, 먼저 데이터와 인사한다

이론 + 실습(02_lab 타이타닉)과 함께

오늘의 여정

2교시, 이렇게 흘러갑니다



새 데이터를 받으면 → ① 첫인상으로 생김새 파악 → ② 빈 칸(결측) 점검 → ③ 그룹으로 나눠 비교 → ④ ' 그래서 무슨 뜻인가' 해석. 오늘 이 흐름을 타이타닉으로 직접 따라갑니다.

1

분석가의 첫 일

데이터와 '인사'부터 한다 — EDA



질문

**낯선 데이터 파일을 처음 받으면,
가장 먼저 무엇을 해야 할까?**

바로 그래프부터? 평균부터? — 아니다.

먼저 '데이터와 인사'한다

어떤 정보가, 몇 개나, 어떻게 생겼고,
어디가 비었는지부터 본다.

모르고 분석에 뛰어들면 함정(이상치·결측·치우침)에 그대로 빠진다.

왜 '먼저 보기'가 중요한가

바로 분석하면 생기는 일

① 그냥 평균부터 구하면

요금 평균 32 → '보통 32쯤 내는구나'

사실은 512짜리 극단값이 평균을 끌어올림.
빈 칸(결측)도 모른 채 계산.

→ 첫 단추부터 틀린다.

② 먼저 인사(EDA)하면

규모·타입·결측·분포를 먼저 파악.

'요금은 극단값이 있으니 중앙값을 보자',
'나이가 177명 비었으니 채우자' 판단.

→ 올바른 분석의 출발점.

2

첫인상 5종 세트

다섯 가지 도구로 데이터를 훑는다

데이터와 인사하는 5가지 도구

무엇을 알려주나 (코드는 외울 필요 없다)

`head( )`

맨 위 몇 줄 — "어떻게 생겼나" 눈으로 확인

`shape`

행 수 × 열 수 — "규모" — 몇 명, 정보 몇 개

`info( )`

타입 + 결측 — "빈 칸이 어디에" — 가장 중요!

`describe( )`

숫자 요약 — 평균·중앙값·최소·최대 한 번에

`value_counts( )`

범주별 개수 — "각 종류가 몇 개" 분포

info() 의 핵심

가장 먼저 '빈 칸(결측)'을 찾아라

전체 891명인데 나이는 714명만 있다 → 177명이 비었다(결측).

빈 칸을 모르고 평균·그래프를 그리면 잘못된 결론. 채울지 버릴지는 3교시에서.

describe() 읽는 법

숫자 요약에서 '함정'을 읽어낸다

- 평균(mean)과 중앙값(50%)을 '같이' 본다 — 둘이 크게 다르면 치우쳤다는 신호
 - 타이타닉 요금: 평균 32 vs 중앙값 14 → 극단값(512)이 평균을 끌어올림 = 평균의 함정
- 최솟값·최댓값으로 이상치를 감지 — 나이 최소 0.42세(아기), 최대 80세
- → '평균 하나'를 믿지 말고, 분포를 의심하라 (1교시 복습)

3

나눠보면 보인다

groupby — 전체의 평균은 거짓말한다

그룹별로 쪼개기

'전체 하나의 숫자'를 의심하고 나눠라


전체 생존율 38% 라는 한 숫자로는 아무것도 모른다.

등급별로? 성별로? 나누는 순간 이야기가 드러난다.

타이타닉 — 나눠 볼수록 선명해진다

같은 데이터, 쪼갬수록 진실에 가까워짐

38%
전체 생존율



63% → 24%
1등석 vs 3등석

74% vs 19%
여성 vs 남성

등급 × 성별을 '동시에' 나눠 보면 —

3등석 여성(50%) > 1등석 남성(37%)

"돈(등급)"보다 "성별"이 생사를 더 강하게 갈랐다. 등급만 봤다면 놓쳤을 진실.

전체를 뭉뚱그린 '하나의 평균'은 거짓말을 한다.
의미 있는 그룹으로 '나뉘 볼' 때 진실이 보인다.

— 1교시 '심슨의 역설'이 여기서 살아난다

4

그래서, 무슨 뜻인가

숫자를 '결론'으로 잇는 힘 = 사람의 몫

어떤 분석 결과든, 이걸 던져라

- ① 분포부터 봤나? 평균 하나만 믿지 않았나
- ② 평균의 함정은? 극단값이 평균을 끌어올리지 않았나
- ③ 나눠보면 다른가? 그룹으로 쪼개면 결론이 바뀌나(심슨)
- ④ 상관 ≠ 인과? 같이 움직인다고 원인은 아니다
- ⑤ 일반화 가능? 이 데이터(표본)로 단정해도 되나

같은 결과, 다른 해석

초보는 숫자를 읽고, 분석가는 '의미'를 읽는다

■ 초보의 해석

"여성 생존율이 74%네. 끝."

숫자를 그대로 옮겨 적는다.
'왜'와 '그래서'가 없다.

✓ 분석가의 해석

"성별이 등급보다 생사를 더 갈랐다.
3등석 여성이 1등석 남성보다 더 살았다 —
'여성·어린이 먼저'가 돈보다 우선했다."

숫자 → 한 문장의 '결론'으로 읽는다.

도구(head·groupby·차트)는 AI가 대신 써줄 수 있다.
하지만 '나눠 볼까?' 묻고 '그래서 무슨 뜻이지?' 답하는 건,
여전히 사람의 몫이다.

이제, 02_lab에서 직접 타이타닉을 분석해봅시다 →