

초급 데이터 분석 · 3교시

지저분한 데이터 길들이기 — 정제의 기술

— 분석가 시간의 절반 이상은 '청소'다

이론 + 실습(03_lab 부동산·금융)과 함께

3교시, 이렇게 흘러갑니다

- ① 현실 데이터는 왜 지저분한가 — Garbage In, Garbage Out
- ② 타입 바로잡기 — "18,300"은 글자라 평균도 못 구한다
- ③ 결측치(빈 칸) — 탐색·시각화하고, 상황에 맞게 처리
- ④ 정제도 '판단'이다 — 무엇을 버리고 무엇을 채울까

1

현실 데이터는 지저분하다

교과서 데이터는 깨끗하지만, 진짜는 다르다



질문

교과서·예제 데이터는 늘 깔끔한데, 실무 데이터는 받아보면?

빈 칸, 이상한 글자, 중복... 그대로는 분석이 안 된다.

분석가의 현실

시간의 60~80%는 '분석'이 아니라 '정제'

토스 분석가도 "데이터 클렌징 60% · 분석 20% · 공유 20%"라고 말한다.

지저분한 데이터로 분석하면 결과도 쓰레기 — Garbage In, Garbage Out.

지저분함의 3가지 얼굴

무엇을 길들여야 하나

① 잘못된 타입

금액이 "18,300"처럼
쉼표 든 '글자'로 저장.

숫자가 아니라
평균조차 못 구함.
→ 숫자로 변환

② 결측치(빈 칸)

수집 누락·응답 거부.
시스템 오류로 생긴 NaN.

빈 칸인 채 평균·그래프 →
잘못된 결론.
→ 버리거나 채운다

③ 이상치·중복

오타·중복 입력.
말도 안 되는 값(나이 999).

평균을 왜곡하고
곡을 두 번 센다.
→ 확인·제거

2

타입 바로잡기

컴퓨터가 '숫자'로 인식해야 계산된다

"18,300"(글자) vs 18300(숫자)

쉼표가 들어간 글자는 더하지도 평균 내지도 못한다.

쉼표 제거 → 숫자로 변환해야 비로소 분석 가능. 날짜는 날짜 타입으로.

3

결측치 — 오늘의 핵심

빈 칸을 '보고', 상황에 맞게 '메운다'

먼저 '어디가, 얼마나' 비었나

숫자로 세고, 그림으로 패턴을 본다

- 결측 개수 세기 — 어느 컬럼이 얼마나 비었나
 - 막대그래프: 컬럼별 결측 개수 → '얼마나 심각한가'
 - 히트맵(결측 지도): 어느 '위치'가 비었나 → 한 컬럼에 몰렸나, 무작위인가
- 패턴이 중요 — 한 컬럼만 거의 비었다면 그 컬럼을 버리는 게 답일 수도

결측 처리 5가지 — 언제 무엇을

정답은 없다. 상황에 맞게 고른다

컬럼 버리기

거의 다 비었을 때 (예: 80%+ 결측)

행 버리기

결측이 아주 적을 때 (전체의 극소수)

대표값 채우기

평균/중앙값/최빈값 — 수치는 중앙값(평균함정), 범주는 최빈값

앞뒤값·보간

시계열 — 앞뒤 값으로 잇거나 부드럽게 보간

알고리즘(KNN)

비슷한 '이웃'을 찾아 추정 — 가장 정교

4

정제는 '판단'이다

무엇을 버리고 무엇을 채울지 = 사람의 결정

채우는 것도 공짜가 아니다

정제 선택의 트레이드오프

평균으로 채우면?

빈 칸이 모두 '평균'이 됨.

→ 데이터가 평균 쪽으로 뭉쳐
'분산(다양성)'이 줄어든다.
억지로 메운 값일 뿐.

행을 버리면?

깔끔하지만 '표본'이 줄어든다.

결측이 특정 그룹에 몰렸다면
→ 그 그룹이 통째로 사라져
편향이 생길 수도.

그래서 '왜 비었나·버려도 되나·채운 값이 분포를 왜곡 안 하나'를 묻는다 — AI는 이 판단을 대신 못 한다.

정제는 '잡일'이 아니라 분석의 첫 단계다.
어떻게 정제하느냐가 결과를 바꾼다.

이제 03_lab에서 지저분한 데이터를 직접 길들여 봅시다 →