

초급 데이터 분석 · 5교시

데이터로 이야기를 완성하다 — 분석가의 길

— 5시간이 준 것은 도구가 아니라 '사고방식'

종합 + 프로젝트(월드컵·Spotify) + 다음 걸음

오늘의 여정

5교시, 이렇게 마무리합니다

- ① 분석의 전체 흐름 — 입수→정제→분석→시각화→해석 한 바퀴
- ② 분석가의 진짜 일 — 현장은 '쿼리'가 아니다
- ③ AI 시대의 분석 — 무엇이 사람의 몫으로 남는가
- ④ 다음 걸음 — 셀프스터디 로드맵


1

분석의 전체 흐름

1~4교시가 사실은 '한 파이프라인'이었다

데이터 분석 5단계 파이프라인

오늘 캡스톤·프로젝트로 직접 완주



이 흐름은 데이터가 축구든(월드컵 캡스톤) 음악이든(Spotify 프로젝트) 똑같다. 오늘 두 프로젝트로 처음부터 끝까지 직접 돌려본다.

2

분석가의 진짜 일

현장에서 건진 교훈 — 분석은 '쿼리'가 아니다

실무 분석가는 이렇게 일한다

한국 현장 사례 (1교시 사례편 복습)

토스

일의 비중: 클렌징 60%·
분석 20%·공유 20%.

'로그 설계'부터 직접 —
분석은 쿼리가 아니라
설계에서 시작된다.

토스플레이스 PANDA

데이터 요청의 70%가
복잡한 분석이 아니라
단순 '수치 조회'였다.

→ 병목을 발견·자동화하는
것도 분석가의 일.

우아한형제들

같은 지표도 '정의'에
따라 숫자가 달라진다.

숫자에 '맥락'을 입히고
정의를 합의하는 것,
그게 분석가의 몫.

분석가는 SQL을 치는 사람이 아니라,
비즈니스와 기술의 다른 언어를 '데이터로 잇는 통역사'다.

3

의료 데이터를 분석할 때

여러분의 분야 — 일반 데이터와 무엇이 다른가

의료 데이터의 3가지 특성

조심하지 않으면 결론이 틀어진다

① 결측이 '정보'다

검사를 '안 받은' 환자 =
건강해서 안 했거나,
너무 위중해서 못 했거나.

결측이 무작위가 아니다!

→ 무조건 평균으로 채우면 안 됨

② 이상치 ≠ 오류

혈압 200을 '이상치'라고
무조건 지우면?

진짜 '중증 환자'를
통째로 버리는 것.

→ 확인 후 판단, 무조건 제거 금지

③ 단위·기준 통일

기관·시기마다 검사 단위·
정상 기준치가 다르다.

합치기 전 단위를
반드시 통일.

→ 안 하면 엉터리 비교

조금 더 깊이

환자 차트에 '혈압'이 비어 있다 — 왜 안 잤을까?

같은 '빈 칸'이라도 비워진 '이유'가 다르면, 처리하는 법도 달라집니다. 세 가지 경우를 봅시다.

① 그냥 우연히 빠짐

그날 혈압계가 고장나서
아무 환자나 무작위로 누락.

누가 빠질지 예측도 안 되고
데이터와 아무 상관 없음.

→ 버려도 큰 문제 없음
(통계 용어: MCAR)

② 다른 데서 이유가 보임

젊고 건강한 환자는
혈압을 잘 안 잤다.

'나이'를 보면 누가 빠졌는지
설명이 된다.

→ 나이 등으로 채울 수 있음
(통계 용어: MAR)

③ 빠진 것 자체가 신호

너무 위중해서 혈압 잤
새도 없었다.

'비어 있다' = 곧 '위중'.
평균으로 채우면 위중 환자가
'평범'으로 둔갑! (위험)

→ 함부로 채우면 안 됨
(통계 용어: MNAR)

핵심: 우연이면(①) 버려도 OK. 하지만 '빈 칸 자체가 정보'(③)면 함부로 못 버린다 — 그래서 채우기 전에 '왜 비었나'부터 묻습니다.

의료 데이터의 새 '함정'

'정확도 99%'에 속지 마라

정확도의 함정 (클래스 불균형)

환자 10명 + 정상 990명 (희귀병).

"전부 정상"이라고 찍기만 해도
정확도 = 99% !

하지만 진짜 환자 10명을 다 놓쳤다.
→ 중요한 건 '환자를 놓치지 않는 것'.
정확도(accuracy)는 거짓말할 수 있다.

미래를 훔쳐보기 (Data Leakage)

'미래의 검사값·결과'를 예측 재료
(피쳐)에 살짝 섞으면?

시험 답을 미리 본 것과 같다.
점수는 높지만 실전에선 무용지물.

→ '예측 시점 이후'의 정보는 금지

데이터만 보면 틀린다

숫자 뒤엔 '임상'과 '사람'이 있다

임상 전문가와 함께

상병코드(ICD)·처방코드(EDI) 같은
코드값 해석엔 임상 지식이 필요.

데이터만 보고 판단하면 틀린다.
→ 도메인(임상) 전문가 검증은 필수

개인정보·규제 (보안과도 직결)

의료 데이터는 함부로 못 쓴다.
비식별화·가명처리, 환자 동의,
IRB(연구윤리) 승인 범위 내 사용.

→ '분석 전에' 지켜야 할 약속

의료IT·스마트보안 전공자에게 특히 중요 — 코드는 임상 검증, 데이터는 법·가이드라인 준수.

더 깊이 가고 싶다면 — 키워드

오늘은 '조심할 게 있다'만, 실무에선 이것 찾아보라

- 결측 메커니즘 — MCAR / MAR / MNAR (결측이 '왜' 생겼나)
- 평가지표 — AUROC · AUPRC · 민감도/특이도 · PPV/NPV (불균형일 때 accuracy 대신)
- Data leakage 방지 — 시점 분리, 미래 정보 차단
- 편향 — 선택 편향(특정 병원 데이터)·측정 편향
- 규제 — 개인정보보호법·가명정보 가이드, 보건의료데이터 활용 가이드라인, IRB

4

AI 시대의 데이터 분석

무엇이 사람의 몫으로 남는가

AI가 하는 일 vs 사람이 하는 일

경계가 분명해진다



AI가 잘하는 일

- 코드 작성 (pandas·seaborn)
- 요약·정리·초안
- 빠른 계산·추출

→ 점점 더 잘하게 된다



사람의 몫

- 좋은 질문 던지기
- 결과 의심·검증
- 함정(평균·심슨·인과) 피하기
- 해석 → 의사결정

→ 값이 점점 오른다

통념을 데이터로 검증하라

Spotify 프로젝트가 보여준 것

- "신나는 곡이 인기" → 음향 수치와 인기 상관은 거의 0 ❌
- "짧은 곡이 인기"(틱톡) → 이 데이터에선 성립 안 함 ❌
- "K-pop은 빠르다" → 평균보다 오히려 느린데 인기는 2위 ❌
- → AI에게 '히트곡 공식'을 물으면 그럴듯한 답을 준다. 하지만 '진짜야?'하고 데이터로 따지는 건 사람의 일.

정답을 받아 적지 말고,
내가 놓친 질문을 받아내라.

5

다음 걸음

이 5시간을 어떻게 이어갈까

늘 곁에 둘 5문 체크리스트

어떤 데이터를 분석하든, 이것 던져라

- ① 분포부터 봤나? 평균 하나만 믿지 않았나
- ② 평균의 함정은? 극단값이 평균을 끌어올리지 않았나
- ③ 나눠보면 다른가? 그룹으로 쪼개면 결론이 바뀌나(심슨)
- ④ 상관 ≠ 인과? 같이 움직인다고 원인은 아니다
- ⑤ 일반화 가능? 이 데이터(표본)로 단정해도 되나

오늘 배운 흐름을 '새 데이터'로 반복하라

- 관심 있는 데이터를 찾는다 — 공공데이터포털·Kaggle·내 일상 기록
- 오늘의 5단계로 한 바퀴 — 입수→정제→분석→시각화→해석
- 작게 시작해 '한 문장 결론'까지 — 포트폴리오로 정리(실수 6·팁 4 기억)
- AI를 '비판의 도구'로 — '내 분석의 허점을 공격해줘'

도구는 변해도,
좋은 질문을 던지고 결과를 해석하는 힘은
사람의 몫이다.

— 5시간, 수고하셨습니다 🎉